

Bases de datos vectoriales

Fundamentos, búsqueda y administración

Caso práctico: buscador de jugadores de fútbol

UTN · Facultad Regional La Plata
Administración de Sistemas de Información · 2026

El problema de encontrar información

Consulta

«automóvil»

Coincidencia léxica
Busca términos y sus variantes

Contenido disponible

«coche»

Recuperación semántica
Compara representaciones

La similitud ayuda a encontrar candidatos; las restricciones verifican requisitos.

Qué almacena una base vectorial

Parte del registro	Función
Identificador	Reconocer una entidad
Vector	Buscar por similitud
Metadatos	Filtrar: posición, edad, liga
Documento o referencia	Mostrar y verificar evidencia

Relacional y vectorial se complementan: exactitud de atributos + similitud.

Vectores, embeddings y dimensiones

Texto del perfil

«Delantero con regate y desborde»


↓ Modelo de embeddings

[0,018, -0,074, 0,109, ...]

384 componentes en MiniLM · números ilustrativos

Mismo modelo para perfiles y consulta

Similitud coseno



SIMILITUD COSENO

0,000

DISTANCIA = 1 - COSENO


1,000

Direcciones perpendiculares:
similitud cero.

Modelo geométrico en 2D. En el buscador, MiniLM produce 384 dimensiones. Una similitud alta no es una probabilidad de acierto.

$$\cos(a,b) = (a \cdot b) / (\|a\| \|b\|) \quad \cdot \quad \text{distancia} = 1 - \cos(a,b)$$

Vecinos próximos: búsqueda exacta y ANN



Exacta


Compara todos
los vectores elegibles

Aproximada (ANN)

Explora una parte;
puede omitir vecinos

Ejemplo sintético · $Q = (4, 1)$, $k = 3$ · menor distancia implica mayor cercanía

HNSW: navegación por capas




Exploramos E desde F. La distancia baja de 120 a 25 unidades: E mejora el candidato.

Más exploración puede mejorar cobertura, con mayor costo de búsqueda.

Recorrido simplificado; no es el índice interno de Chroma.

Top-k y filtros de metadatos



3 elegibles · 3 de 3 resultados

Perfil	Edad	Distancia
A · ST	22	0,000
F · ST	19	0,189
J · ST	25	0,433

★ Consulta Q • Vecino seleccionado ○ Elegible × Excluido por filtro

Perfiles A–L inventados para enseñar. Sus coordenadas no son embeddings reales ni estadísticas de futbolistas. ST: delantero; CM: mediocampista; CB: central; GK: arquero.

Filtros → universo elegible | **similitud → orden** | **k → cantidad**

Persistencia, actualización y escala

Responsabilidad	Decisión de administración
Persistencia	Reutilizar y respaldar la colección
Actualización	Versionar fuente, perfil y modelo
Distribución	Particiones, réplicas y consistencia

$N \times D \times 4$ bytes

31,37 MB

Vectores float32: estimación del contenido numérico, sin grafo, documentos ni modelo.

Arquitectura: ingesta y consulta

INGESTA · cuando cambia la fuente

Fuente → Perfiles → Embeddings → Colección

CONSULTA · ante cada búsqueda

Pregunta → Embedding + filtros → Vecinos

El modelo conecta ambos caminos; la metadata conserva identidad y procedencia.

Tecnologías y aplicaciones

Chroma · Qdrant · pgvector

Caso publicado	Qué permite explicar
LinkedIn	Estructurar relaciones para recuperar contexto
DoorDash	Controlar calidad de respuestas RAG
Spotify / Voyager	Buscar vecinos sin modelo generativo

La elección depende de fuentes, escala, operación y requisitos de acceso.

Dónde participa la base vectorial en RAG

Consulta

- ↓ Recuperación de evidencia
- ↓ Contexto con perfiles y referencias
- ↓ **Generación de una respuesta**

La base recupera. El LLM redacta. La evidencia requiere verificación.

Nuestro buscador de jugadores

20.421

perfiles vectorizados

384

dimensiones por vector

Chroma / HNSW / coseno

Filtros exactos → pool de vecinos → ranking por atributos

FIFA/EA FC 24 · actualización 2 · 22/09/2023

Valoraciones del videojuego, no rendimiento real actualizado

Demostración: delantero con regate

Jugador	Regate	Distancia coseno
Kylian Mbappé	92	0,5458
Antoine Griezmann	88	0,4895
Gabriel Jesus	88	0,5048
Christopher Nkunku	88	0,5243
Wissam Ben Yedder	87	0,4988

ST · k = 5 · 3.194 elegibles · orden final por regate

Respaldo: consulta registrada el 12/09/2026, sin LLM. No es una captura en vivo.

Conclusiones y límites

01 Representar no garantiza comprender

02 Similitud, filtros y ranking cumplen funciones distintas

03 La calidad exige fuentes, evaluación y mantenimiento

Datos históricos · sin evaluación etiquetada de relevancia · generación opcional